

1)

الف) برای کلاس k ام اثبات می‌کنیم نتیجه قابل تعمیم به همه کلاس‌ها است.

$$P(\text{Error}) = \sum_j P(y \neq k, x \in R_j), j \neq k + \sum_i P(y \neq k, x \in R_k), i \neq k + P(y \neq k, x \in R_k)$$

$$= P(y \neq k) + \left(\sum_i P(y \neq k, x \in R_k), i \neq k - P(y \neq k, x \in R_k) \right) \rightarrow A$$

$$A = \int_{R_k} \left(\sum_i \frac{P(x, y \neq i)}{P(x)P(y \neq i|x)} - \frac{P(x, y \neq k)}{P(x)P(y \neq k|x)} \right) dx = \int_{R_k} P(x) \left(\sum_i \frac{P(y \neq i|x)}{P(y \neq i|x)} - \frac{P(y \neq k|x)}{P(y \neq k|x)} \right) dx$$

روی ناحیه k ام I_1 بزرگ‌تر از I_2 است یعنی $P(y \neq k|x)$ در ناحیه R_k بزرگ‌تر از جایی کلاس‌ها در آن نامیده می‌شود.

با این فرمول منفی است و کاهشده خطا است. این قابل تعمیم به تمام کلاس‌ها است لذا در مجموع خطا کمینه می‌شود.

(ب)

بیز کلاسی را انتخاب می‌کنیم که $P(y \neq i|x)$ آن از همه بیشتر باشد. حال اگر M کلاس داشته باشیم فضا به M قسمت افراز می‌شود لذا $\sum_{i=1}^M P(y \neq i|x) = 1$

15 حال چون $\sum_{i=1}^M P(y \neq i|x)$ پس باید حداقل یکی از آن‌ها زیر $\frac{1}{M}$ قرار گیرد. حال اگر فرض کنیم کلاس k ام انتخاب شده:

$$P(y \neq k|x) = \max_i P(y \neq i|x) \geq \frac{1}{M}, I_1$$

$$\rightarrow P(\text{Error}) = 1 - P(y \neq k|x) \stackrel{(I_1)}{\rightarrow} \leq 1 - \frac{1}{M} = \frac{M-1}{M} \checkmark$$

20 (ج) دوروی پیشنهاد می‌کنیم:

روشنی اول: برای هر کلاس به طور 1vsall نگاه کنیم و یک ROC بگیریم.


روشنی دوم: برای هر th تمام کلاس‌ها را دو دسته می‌گیریم، در نهایت روی همه اعداد به دست آمده میانگین می‌گیریم و خروجی برای آن th به دست می‌آید. این کار را برای همه th ها تکرار می‌کنیم.

25 (د) فرضی که در naive bayes می‌کنیم استقلال متغیرهاست حال اگر مجموعه داده وجود داشته باشد که بردارها ویژگی مختلف در آن مستقل باشند naive bayes طبقه بندی بهینه است.

2) با مساوی قرار دادن توزیع‌ها داده شده مرز تصمیم درست می‌آید.

$$\frac{x}{\sigma^2} \exp\left(-\frac{x^2}{2\sigma^2}\right) = \theta x \exp(-\theta x) \xrightarrow{\ln} -2\ln\sigma - \frac{x^2}{2\sigma^2} = \ln\theta - \theta x$$

$$\Rightarrow x^2 - 2\sigma^2\theta x + 2\sigma^2(\ln\theta\sigma^2) = 0 \Rightarrow x = \theta\sigma^2 \pm \sigma\sqrt{\sigma^2\theta^2 - 2\ln\theta\sigma^2}$$



3) (الف)

$$\text{risk} = \int_{R_1} \lambda_{12} P(\omega_2) P(x|\omega_2) dx + \int_{R_2} \lambda_{21} P(\omega_1) P(x|\omega_1) dx$$

$$= \lambda_{12} \int_{R_1} P(x|\omega_2) dx + \lambda_{21} \int_{R_2} P(x|\omega_1) dx \quad P(\omega_2) = P(\omega_1) \text{ با فرض}$$

$$\xrightarrow{\lambda_2 = \lambda_{21} = 1} \int_{R_2} P(x|\omega_1) dx = \int_{R_1} P(x|\omega_2) dx \quad \checkmark$$

(ب) بدون فرض $P(\omega_1) = P(\omega_2)$ قیمت الف صریح نخواهد بود لذا همواره پاسخ یکتا نخواهد بود و اگر این شرط برقرار نباشد نتیجه قیمت الف درست نیست.

4) برای حل این سوال با استفاده از $\ln$ مسئله به سادگی حل می‌شود.

$$A \quad \ln(P(\mu|x)) = \sum_{k=1}^N \ln(P(x_k|\mu)) + \ln(P(\mu)) = - \sum_{k=1}^N \frac{(x_k - \mu)^2}{2\sigma^2} + \ln\mu - \frac{\mu^2}{2\sigma^2\mu} - \ln\frac{\sigma^2}{\mu}$$

$$\frac{\partial A(\mu)}{\partial \mu} = - \sum_k \frac{\mu - x_k}{\sigma^2} + \frac{1}{\mu} - \frac{\mu}{\sigma^2\mu} = 0 \Rightarrow \dots \Rightarrow \left(\frac{N}{\sigma^2} + \frac{1}{\sigma^2\mu}\right)\mu^2 - 2\mu - 1 = 0$$

$$\Rightarrow \mu_{\text{MAP}} = \frac{2}{2R} \left(1 + \sqrt{1 + \frac{4R}{2}}\right) \quad \checkmark$$

5) (الف)

$$L(\theta|D) = p(D|\theta) = \prod_{i=1}^n p(y_i|\theta), \quad \hat{\theta}_{\text{ML}} = \arg \max_{\theta} L(\theta|D) = \arg \max_{\theta} \sum_{i=1}^n \ln(p(y_i|\theta))$$

$$\Rightarrow \nabla_{\theta} \ln(p(y_i|\theta)) = 0 \Rightarrow \sum_{i=1}^n -\frac{1}{\theta} + \frac{y_i r}{\theta^2} = 0 \Rightarrow \hat{\theta}_{\text{ML}} = -\frac{1}{n} \sum_{i=1}^n y_i r$$

(ب) وقتی بی نهایت مشاهده داشته باشیم MAP به MLE میل می‌کند.