

به نام خدا



دانشگاه تهران



دانشکده مهندسی برق و کامپیوتر

درس یادگیری ماشین

تمرین سوم

نام و نام خانوادگی	امیر غرقابی
شماره دانشجویی	۸۱۰۱۰۲۲۱۷
تاریخ ارسال گزارش	۱۴۰۲،۱۰،۰۴

پاسخ ۱.

Subject:
Date:

امیر غفرانی

تمرین یادگیری ماشین

810102217

HW3

(1)

1.1) $\beta_0 = ?$

$$y = \beta_0 + \epsilon_i \quad \beta_0 = \text{mean}(y) = \frac{\sum y_i}{10} = \frac{46 + 80 + \dots + 30}{10} = 56.1$$

1.2) $\beta_1 = ?$

$$y = \beta_0 + \beta_1 x_i + \epsilon_i$$

$$\arg \min_{\beta_1} \frac{1}{n} \sum (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum (y_i - \beta_1 x_i - \epsilon_i)^2$$

$$\frac{d}{d\beta_1} \frac{1}{n} \sum 2x_i (y_i - \beta_1 x_i - \epsilon_i) = 0$$

$$= \frac{2}{n} \sum -y_i x_i + \beta_1 x_i^2 + x_i \epsilon_i = 0 \quad \rightarrow \quad \sum \beta_1 x_i^2 = \sum y_i x_i$$

$$\rightarrow \beta_1 \sum x_i^2 = \sum x_i y_i \quad \rightarrow \quad \beta_1 = \frac{\sum x_i y_i}{\sum x_i^2} = 3$$

$$\hat{y} = 25 + \frac{1}{2} x \quad \underline{1.3}$$

لرزشها انقدر کم خواهد بود زیرا که سیمون تنها یکین را در دست می دهد بنا براین

~~احتمال دارد که سیمون تنها یکین را در دست می دهد بنا براین~~
لرزشها انقدر کم خواهد بود زیرا که سیمون تنها یکین را در دست می دهد بنا براین


P4PCO

$$\sum (y - \hat{y})^2 = 7 \quad ; \quad \sigma^2 = \frac{SS E}{16-2} = \frac{7}{14} = 0.5$$


1.4

پاسخ ۲ -


رسم تابع سیگموئید:



شکل ۱. تابع سیگموئید به ازای $w=1$



شکل ۲. تابع سیگموئید به ازای $w=5$



شکل ۳. تابع سیگموئید به ازای $w=100$

در وزن های بالا، تابع سیگموئید به صورت یک پله عمل می کند در واقع کاملاً باینری عمل می کند به همین دلیل logistic regression ممکن است دچار اورفیت شود.

۱۲ در فایل گزاشی ۲.۱

۲.۲

$$\max \prod P(y_i | x_i, w) \cdot P(w)$$

$$\log \rightarrow \sum [\log P(y_i | x_i, w) + \log P(w)] = \sum \log P(y_i | x_i, w) + n \left(\log \frac{1}{\sqrt{2\pi}} - \frac{1}{2} \right)$$

Subject: _____
Date: _____

$$x^1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad y_1 = 1$$

$$x^2 = \begin{bmatrix} -1 \\ 2 \end{bmatrix} \quad y_2 = -1$$

$$x^3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix} \quad y_3 = 1$$

(3)

~~حل سوال~~

$$L = \underbrace{\frac{1}{2} \|w\|^2}_{\substack{\text{L} \\ (1 - y_i (w^T x_i + b))}} + \underbrace{[\lambda_1 \quad \lambda_2 \quad \lambda_3]}_{\substack{\text{L} \\ (1 - y_i (w^T x_i + b))}}$$

شرط kT

$$\left(\frac{\partial L}{\partial w} \right)^T = w - \lambda_1 y_1 x_1 - \lambda_2 y_2 x_2 - \lambda_3 y_3 x_3 = 0$$

$$\rightarrow w = \sum \lambda_i y_i x_i$$

$$\left(\frac{\partial L}{\partial b} \right)^T = \sum \lambda_i y_i = 0$$

$$\lambda_i \geq 0$$

~~حل سوال~~

$$\Rightarrow -\frac{1}{2} \sum \lambda_i \lambda_j y_i y_j x_i^T x_j + \sum \lambda_i$$

~~حل سوال~~

$$\frac{\partial L}{\partial \lambda_1} = -\frac{1}{2} x_1^2 y_1^2 x_1^T x_1 - \lambda_2 y_2 y_2 x_1^T x_2 - \lambda_3 y_3 y_3 x_1^T x_3 + 1 = 0$$

$$\frac{\partial L}{\partial \lambda_2} = -\lambda_1 y_1 y_2 x_1^T x_2 - \lambda_2 y_2^2 x_2^T x_2 - \lambda_3 y_2 y_3 x_2^T x_3 + 1 = 0$$

$$\frac{\partial L}{\partial \lambda_3} = -\lambda_1 y_1 y_3 x_1^T x_3 - \lambda_2 y_2 y_3 x_2^T x_3 - \lambda_3 y_3^2 x_3^T x_3 + 1 = 0$$

APCO

Subject: _____
Date _____

$$\begin{aligned} \rightarrow 5\lambda_1 + 3\lambda_2 + 5\lambda_3 &= 1 \\ \rightarrow 3\lambda_1 + 5\lambda_2 + 3\lambda_3 &= 1 \\ \rightarrow 5\lambda_1 + 3\lambda_2 + 5\lambda_3 &= 1 \end{aligned} \quad \left. \vphantom{\begin{aligned} \rightarrow 5\lambda_1 + 3\lambda_2 + 5\lambda_3 &= 1 \\ \rightarrow 3\lambda_1 + 5\lambda_2 + 3\lambda_3 &= 1 \\ \rightarrow 5\lambda_1 + 3\lambda_2 + 5\lambda_3 &= 1 \end{aligned}} \right\} \rightarrow \begin{aligned} \lambda_1 &= 0 \\ \lambda_2 &= \frac{1}{8} \\ \lambda_3 &= 8 \end{aligned}$$

~~$w = -\sum \lambda_i y_i x_i = -\frac{1}{8} \begin{bmatrix} -1 \\ 2 \end{bmatrix} + \frac{1}{8} \begin{bmatrix} -1 \\ -2 \end{bmatrix} = \begin{bmatrix} 0 \\ -\frac{1}{2} \end{bmatrix}$~~

$$w = -\sum \lambda_i y_i x_i = -\frac{1}{8} \begin{bmatrix} -1 \\ 2 \end{bmatrix} + \frac{1}{8} \begin{bmatrix} -1 \\ -2 \end{bmatrix} = \begin{bmatrix} 0 \\ -\frac{1}{2} \end{bmatrix}$$

$$y = w_1 x_1 + w_2 x_2 + b \Rightarrow -\frac{1}{2} x_2 + b = -1 \rightarrow -1 + b = -1 \rightarrow b = 0$$

$$\rightarrow y = -\frac{1}{2} x_2$$

(۴)

هدف استفاده از کرنل در SVM این است که دیتای ورودی را گرفته

و آنرا به فرم مورد نیاز تبدیل کند. تا بتوان داده را به وسیله یک خط

یا یک ابر صفحه جدا کرد

$$4.2 \quad k(n, n') = k_1(n, n') k_2(n, n')$$

$$k_1(n, n') = a^T(n) a^T(n') \quad ; \quad k_2 = b^T(n) b^T(n')$$

$$a(n) = \begin{bmatrix} a_1(n) \\ \vdots \\ a_m(n) \end{bmatrix}$$

$$b(n) = \begin{bmatrix} b_1(n) \\ \vdots \\ b_n(n) \end{bmatrix}$$

$$k_1(n, n') k_2(n, n') = \sum_{i=1}^m a_i(n) a_i(n') \cdot \sum_{j=1}^n b_j(n) b_j(n')$$

$$\sum_i \sum_j (a_i(n) b_j(n)) (a_i(n') b_j(n')) = C^T(n) C(n') = k_3(n, n')$$

۵-۱.

در ابتدا دیتا بصورت دیتافریم (به کمک کتابخانه Pandas) خوانده می شود.

دیتا توسط کتابخانه info نمایش داده می شود:

```
DataFrame Information:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   Email                  500 non-null   object 
1   Address                500 non-null   object 
2   Avatar                 500 non-null   object 
3   Avg. Session Length    500 non-null   float64 
4   Time on App            500 non-null   float64 
5   Time on Website        500 non-null   float64 
6   Length of Membership    500 non-null   float64 
7   Yearly Amount Spent     500 non-null   float64 
dtypes: float64(5), object(3)
memory usage: 31.4+ KB
None
```

شکل ۱. نمایش اطلاعات دیتاست به کمک کتابخانه info

شکل بالا نشان می دهد که این دیتاست شامل ۵۰۰ نمونه است و برای هر نمونه مقادیر ایمیل، آدرس، رنگ پروفایل، میانگین طول جلسات مشاوره، میانگین تایم گذرانده شده در اپلیکیشن بعد از جلسه، و ... مشخص شده است.

همچنین با استفاده از کتابخانه describe، مقادیر تعداد، میانگین، و سایر مقادیر آماری هر ستون مشخص شده است.


DataFrame Descriptive Statistics:			
	Avg. Session Length	Time on App	Time on Website \
count	500.000000	500.000000	500.000000
mean	33.053194	12.052488	37.060445
std	0.992563	0.994216	1.010489
min	29.532429	8.508152	33.913847
25%	32.341822	11.388153	36.349257
50%	33.082008	11.983231	37.069367
75%	33.711985	12.753850	37.716432
max	36.139662	15.126994	40.005182

	Length of Membership	Yearly Amount Spent
count	500.000000	500.000000
mean	3.533462	499.314038
std	0.999278	79.314782
min	0.269901	256.670582
25%	2.930450	445.038277
50%	3.533975	498.887875
75%	4.126502	549.313828
max	6.922689	765.518462

شکل ۱. نمایش اطلاعات دیتاست به کمک کتابخانه `describe`

۵-۲.

نمودار توام برای میانگین خرید سالانه بر حسب زمان گذرانده شده در وب سایت در شکل زیر قابل مشاهده است. این نمودار `scatter plot` دو متغیر را با یکدیگر ترکیب کرده است و همچنین این شامل دو هیستوگرام حاشیه است که توزیع هر کدام از متغیر ها را نسبت به دیگری نشان می دهد.




شکل ۲. نمودار توام میزان خرید سالانه و زمان گذرانده شده در وبسایت

نمودارهای حاشیه ای نشان می دهد که تعداد کسانی که حدوداً ۳۷ واحد زمانی را در وبسایت گذرانده اند، بیشتر از کسانی است که زمان کمتر و یا حتی بیشتری را در وبسایت گذرانده اند و همچنین تعداد کسانی که ۵۰۰ واحد پولی خرج کرده اند بیشتر از کسانی است که بیشتر و یا حتی کمتر خرج کرده اند.


۳-۵.

نمودار بخش قبل بر حسب زمان گذرانده شده در اپلیکیشن رسم می شود.



شکل ۳. نمودار توام میزان خرید سالانه و زمان گذرانده شده در اپلیکیشن

این بار نمودار به نسبت حالت قبل، شکل خطی تری دارد و نشان می دهد کسانی که بیش از ۱۲ واحد زمانی را در اپلیکیشن گذرانده اند، به نسبت خرید بیشتری داشتند. اما باز هم تعداد کسانی که ۱۲ واحد زمانی را در اپلیکیشن گذرانده اند، بیشتر از تعداد کسانی است که بیشتر یا کمتر از این مقدار وقت صرف اپلیکیشن کرده اند.



شکل ۴. نمودار دو به دو

نمودار pairplot نشان می‌دهد که تعداد سال‌های اشتراک مشتری، تاثیر زیادی در میزان خرید سالانه دارد. به این دلیل که نمودار میزان خرید سالان برحسب زمان اشتراک مشتری یک ترند صعودی و خطی دارد در واقع سال‌های اشتراک مشتری به طور کلی ارتباط مستقیمی با میزان فروش دارد. بنابراین موثر ترین ویژگی برای فروش، زمان اشتراک مشتری است.

۵-۵.

داده ها به دو گروه ۱. ویژگی و ۲ برچسب (میزان خرید سالانه) تقسیم می شوند.

```

Features (X):
      Email \
0  mstephenson@fernandez.com
1  hduke@hotmail.com
2  pallen@yahoo.com
3  riverarebecca@gmail.com
4  mstephens@davidson-herman.com

      Address      Avatar \
0  835 Frank Tunnel\nWrightmouth, MI 82180-9605  Violet
1  4547 Archer Common\nDiazchester, CA 06566-8576  DarkGreen
2  24645 Valerie Unions Suite 582\nCobbborough, D...  Bisque
3  1414 David Throughway\nPort Jason, OH 22070-1220  SaddleBrown
4  14023 Rodriguez Passage\nPort Jacobville, PR 3...  MediumAquaMarine


Avg. Session Length  Time on App  Time on Website  Length of Membership
0  34.497268  12.655651  39.577668  4.082621
1  31.926272  11.109461  37.268959  2.664034
2  33.000915  11.330278  37.110597  4.104543
3  34.305557  13.717514  36.721283  3.120179
4  33.330673  12.795189  37.536653  4.446308

Lable(y):
0  587.951054
1  392.204933
2  487.547505
3  581.852344
4  599.406092
Name: Yearly Amount Spent, dtype: float64

```

شکل ۵.۵ ردیف اول از ستون ویژگی ها و برچسب (میزان خرید سالانه)

برای بخش پیش پردازش، ابتدا ماتریس heat map رسم می شود تا ستون هایی که همبستگی زیادی دارند حذف شوند (data cleaning)



شکل ۵.۶ ردیف اول از ستون ویژگی ها و برچسب (میزان خرید سالانه)

بنظر می رسد هیچکدام از ستون ها همبستگی بالایی (بیشتر از ۹۰٪) ندارند. بنابراین هیچکدام حذف نمی شوند.

در صورت وجود missing data، آن ها را با میانگین ستون جایگزین میکنیم. البته در این دیتاست missing data وجود نداشت.

داده های غیر عددی حذف می شوند زیرا اطلاعاتی که به یادگیری مدل رگرسیون خطی کمک می کنند را ندارند. (این کار با استفاده از dataframe.drop() انجام گرفته است)

سپس برای اینکه داده ها تاثیر یکسانی روی نتیجه بگذارند، اسکیل می شوند. از کلاس StandardScaler از کتابخانه scikiti-learn استفاده شده تا داده ها استاندارد شوند. متد fit_transform() از فرمول زیر برای اسکیل کردن داده ها استفاده می کند.

$$Scaled = \frac{value - \mu_{value}}{\delta_{value}}$$

۵-۶.

داده ها به دو دسته ترین و تست تقسیم می شوند.

```
X_train shape: (350, 4)
X_test shape: (150, 4)
y_train shape: (350,)
y_test shape: (150,)
```

شکل ۷. تعداد داده های ترین و تست ویژگی ها و لیبل ها

داده ها شامل ۴ ستون ویژگی (میانگین زمان جلسه، زمان اپلیکیشن، زمان وبسایت، و زمان اشتراک) و یک ستون برجسب (مبلغ خرج شده) می باشد.

۵-۷.


از متد LinearRegression در کتابخانه sklearn استفاده شده است تا مدل بر روی داده های ترین fit شود.

۵-۸.

با استفاده از متد predict() میزان خرج شده پیشبینی می شود.

۵-۹.

به کمک کتابخانه matplotlib اسکتر پلات برچسب پیشبینی شده و برچسب اصلی رسم می شود.



شکل ۸. اسکتر پلات پیشبینی مبلغ خرج شده و مقادیر اصلی

۵-۱۰.

ارزیابی مدل به شرح زیر می باشد.


```
x_train shape: (350, 4)
x_test shape: (150, 4)
y_train shape: (350,)
y_test shape: (150,)
```

شکل ۹. مقادیر خطا

۵-۱۱.

در صورتی که مدل به درستی ترین شده باشد و مشکل خاصی نداشته باشد، نمودار اختلاف مقادیر پیشبینی شده و مقادیر واقعی به صورت توزیع گوسی خواهد بود.

میانگین خطاها به طور کلی باید حدود عدد 0 باشد زیرا به همان میزان که خطای مثبت ایجاد شده است، به همان میزان نیز ممکن است خطای منفی ایجاد شود. بنابراین توزیع خطای مطلق، توزیعی بسیار نزدیک به گوسی خواهد داشت. همانطور که در شکل نیز قایل مشاهده است.



شکل ۱۰. نمودار توزیع خطای مطلق (گوسی)

۵-۱۲.

جدول coef فیچر ها در شکل زیر قابل مشاهده هستند.

```
model.coef_
array([25.76252659, 38.32855202,  0.19220992, 61.17355707])
```

شکل ۱۱. ضرایب

اسکیل کردن داده ها از این جهت اهمیت دارند که می توان با استفاده از ضرایب، اهمیت هر فیچر و تاثیر هر کدام از آن ها در خروجی را به وضوح نشان داد اما اگر داده های هر ستون اسکیل نمی شدند فهمیدن تفاوت اهمیت آن ها بسیار سخت خواهد بود.

۵-۱۳.

بیشترین مقدار در جدول ضرایب، مربوط به فیچر چهارم یعنی سال های اشتراک بوده است. همچنین در بخش ۴-۵ نیز بررسی شد که این ویژگی ارتباطی نسبتاً خطی با میزان خرید هر مشتری دارد. بنابراین بهینه ترین سرمایه گذاری شرکت می تواند روی وفاداری هر مشتری باشد. پس از اهمیت مدت زما اشتراک مشتری، زمانی که مشتری در اپلیکیشن گذرانده نیز تاثیر خوبی روی میزان خرید او داشته است بنابراین شرکت می تواند روی توسعه اپلیکیشن خود نیز سرمایه گذاری کند.

پاسخ ۶ - شرکت تبلیغاتی

۶-۱.

دیتاست به صورت df خوانده می شود.

```
DataFrame Information:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 10 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Daily Time Spent on Site              1000 non-null   float64
1   Age                                    1000 non-null   int64
2   Area Income                           1000 non-null   float64
3   Daily Internet Usage                  1000 non-null   float64
4   Ad Topic Line                         1000 non-null   object
5   City                                   1000 non-null   object
6   Male                                   1000 non-null   int64
7   Country                               1000 non-null   object
8   Timestamp                             1000 non-null   object
9   Clicked on Ad                         1000 non-null   int64
dtypes: float64(3), int64(3), object(4)
memory usage: 78.2+ KB
None
```

DataFrame Descriptive Statistics:


	Daily Time Spent on Site	Age	Area Income	Daily Internet Usage	Male	Clicked on Ad
count	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000
mean	65.000200	36.009000	55000.000080	180.000100	0.481000	0.500000
std	15.853615	8.785562	13414.634022	43.902339	0.499889	0.500250
min	32.600000	19.000000	13996.500000	104.780000	0.000000	0.000000
25%	51.360000	29.000000	47031.802500	138.830000	0.000000	0.000000
50%	68.215000	35.000000	57012.300000	183.130000	0.000000	0.500000
75%	78.547500	42.000000	65470.635000	218.792500	1.000000	1.000000
max	91.430000	61.000000	79484.800000	269.960000	1.000000	1.000000

شکل ۱۲. اطلاعات کلی و آماری دیتاست تبلیغاتی

دیتاست شامل ۱۰ ستون و ۱۰۰۰ نمونه است

۶-۲.


نمودار توزیع آماری بر حسب سن.



شکل ۱۳. نمودار توزیع آماری بر حسب سن


۳-۶.

رسم نمودار joint plot




شکل ۱۴. نمودار Jointplot درآمد بر حسب سن

این نمودار نشان می دهد افرادی با حدود سن ۳۰ سال، به نسبت در آمد بیشتری داشته اند.



شکل ۱۵. نمودار زمان گذرانده شده در سایت بر حسب سن

این نمودار نیز نشان می دهد که افرادی با حدود سن ۳۰-۳۵ سال، بیشترین زمان را در سایت صرف کرده اند.



شکل ۱۶. نمودار pairplot با در نظر گرفتن تفاوت کسانی که روی تبلیغ کلیک کرده اند و کلیک نکرده اند

با توجه به پلات های بخش های قبل، نتایج زیر قابل دریافت است.

- بیشترین کسانی که در این مجموعه داده حضور دارند، با حدود سنی ۳۰ سال هستند (۱۴۰ نفر)
- افراد حدود ۲۵-۳۵ سال بیشترین درآمد را دارند.
- افرادی بالای ۳۵ سال بیشتر بر روی تبلیغات کلیک می کنند.

- افرادی که روزانه زمان کمتری را در سایت می گذرانند به نسبت بیشتر روی تبلیغات کلیک می کنند.
- افرادی که روزانه زمان کمتری را در اینترنت می گذرانند به نسبت بیشتر روی تبلیغات کلیک می کنند.

۶-۷.

پیش پردازش:

در ابتدا با استفاده از متد `isnull()` به بررسی `missing data` می پردازیم.

```
Daily Time Spent on Site    0
Age                        0
Area Income                0
Daily Internet Usage       0
Ad Topic Line              0
City                      0
Male                      0
Country                   0
Timestamp                  0
Clicked on Ad              0
dtype: int64
```

شکل ۱۷. تعداد `missing data` در هر فیچر

مشاهده می شود که هیچ `missing data` ای وجود ندارد.

ماتریس هیت مپ نیز رسم می شود تا در صورت وجود ستون های همبسته، یکی از آنها حذف شود.



شکل ۱۸. تعداد `missing data` در هر فیچر

هیچکدام از ستون ها همبستگی بیشتر از ۹۰٪ ندارند.

همچنین ستون‌های Ad Topic Line, City, Male, Country, Timestamp که در رگرسیون خطی استفاده نمی‌شوند نیز حذف می‌شوند.

```
Features (X):
  Daily Time Spent on Site  Age  Area Income  Daily Internet Usage
0          68.95      35    61833.90          256.09
1          80.23      31    68441.85          193.77
2          69.47      26    59785.94          236.50
3          74.15      29    54806.18          245.89
4          68.37      35    73889.99          225.58

Lable(y):
0      0
1      0
2      0
3      0
4      0
Name: Clicked on Ad, dtype: int64
```

شکل ۱۹. داده‌ها و برچسب‌ها قبل از اسکیل شدن

اکنون داده‌ها به مانند سوال ۵ اسکیل می‌شوند. و به دو گروه تست و ترین تقسیم می‌شوند.

```
X_train shape: (700, 4)
X_test shape: (300, 4)
y_train shape: (700,)
y_test shape: (300,)
```

شکل ۲۰. تعداد داده‌های ترین و تست ویژگی‌ها و لیبل‌ها

۸-۶.

در این بخش از کتابخانه LogisticRegression استفاده شده است.

که در فایل پایتون مربوطه قابل مشاهده است.

۹-۶.

پیش‌بینی توسط مدل انجام شده و نتایج در بخش ۶-۱۰ قابل مشاهده است.

۱۰-۶.


نتایج مدل در این بخش قابل مشاهده است.

```
Accuracy: 0.9767
Confusion Matrix:
[[155  2]
 [ 5 138]]
Classification Report:
              precision    recall  f1-score   support

     0       0.97       0.99       0.98        157
     1       0.99       0.97       0.98        143

 accuracy          0.98          0.98          0.98          300
 macro avg          0.98          0.98          0.98          300
 weighted avg          0.98          0.98          0.98          300
```

شکل ۲۱. نتایج مدل **logistic regression**



شکل ۴. ماتریس **confusion**

مشاهده می شود که مدل عملکرد خوبی داشته و $accuracy = 97\%$ نیز بیانگر آن است.

۷-۱.

دیتا را با فرمت encoding=latin-1 زیرا پیش فرض encoding=utf-8 است.

گزارش این دیتاست در تصویر زیر قابل مشاهده است.

```
DataFrame Information:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5572 entries, 0 to 5571
Data columns (total 5 columns):
#   Column      Non-Null Count  Dtype
---  -
0    v1          5572 non-null   object
1    v2          5572 non-null   object
2    Unnamed: 2   50 non-null     object
3    Unnamed: 3   12 non-null     object
4    Unnamed: 4   6 non-null      object
dtypes: object(5)
memory usage: 217.8+ KB
None
```

```
DataFrame Descriptive Statistics:
```

	v1	v2	Unnamed: 2	Unnamed: 3	Unnamed: 4
count	5572	5572	50	12	6
unique	2	5169	43	10	5
top	ham	Sorry, I'll call later	bt not his girfrnd... G o o d n i g h t . . . @ "	GE	GNT.-)"
freq	4825	30	3	2	2

شکل ۲۲. گزارش دیتاست

این دیتاست شامل ۲ ستون است ستون دوم (v2) متن پیامک و ستون اول (v1) برچسب آن است. که شامل ۲ برچسب ham (پیامک غیر اسپم) و Spam است. این دیتاست شامل ۵۵۷۲ نمونه است. این دیتاست شامل ۳ ستون دیگر نیز هستند که در ادامه تنها از دو ستون اول استفاده می شود. داده به نسبت ۷۰-۳۰ به دو دسته تست و ترین تقسیم می شوند.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=101)

print("X_train shape:", X_train.shape)
print("X_test shape:", X_test.shape)
print("y_train shape:", y_train.shape)
print("y_test shape:", y_test.shape)

X_train shape: (3900, 8672)
X_test shape: (1672, 8672)
y_train shape: (3900,)
y_test shape: (1672,)
```

شکل ۲۳. تقسیم داده ها به دو دسته ترین و تست

اکنون از Support Vector Classification (SVC) برای ترین کردن مدل استفاده می شود. برای این کار از دو کرنل مختلف استفاده خواهد شد.

```
Linear Kernel SVM:
Accuracy: 0.9862
Confusion Matrix:
[[1463   1]
 [  22 186]]
Classification Report:
              precision    recall  f1-score   support

   ham           0.99         1.00         0.99         1464
   spam           0.99         0.89         0.94          208

 accuracy          0.99         0.95         0.99         1672
  macro avg           0.99         0.95         0.97         1672
 weighted avg           0.99         0.99         0.99         1672

=====

RBF Kernel SVM:
Accuracy: 0.9629
Confusion Matrix:
[[1464    0]
 [  62 146]]
Classification Report:
              precision    recall  f1-score   support

   ham           0.96         1.00         0.98         1464
   spam           1.00         0.70         0.82          208


 accuracy          0.96         0.85         0.96         1672
  macro avg           0.98         0.85         0.90         1672
 weighted avg           0.96         0.96         0.96         1672

=====
```


شکل ۲۴. نتایج مدل SVM با دو کرنل مختلف

با استفاده از متد `best_estimator_`، بهترین مدل با توجه به hyperparameterهای آن برای هر کرنل انتخاب شده و در نهایی نتیجه چاپ شده است.

با مقایسه ماتریس آشفتگی مشخص می شود که مدل با استفاده از هر دو کرنل در تشخیص ایمیل های Spam کمی ضعیف عمل میکنند با این حال کرنل خطی عملکرد بهتری را از خود نشان داده است. ماتریس های آشفتگی مربوط به هر دو کرنل در زیر قابل مشاهده است.



شکل ۲۵. ماتریس آشفتگی کرنل خطی



شکل ۲۶. مدل SVM با کرنل RBF

Grid search: این روش تمام ترکیبات ممکن از مقادیر hyperparameterها را در یک grid ارزیابی می کند. این روش جست و جو بسیار جامع است و تمام ترکیبات را پوشش می دهد.

Random search: این روش بصورت تصادفی مقادیر hyperparameterها را نمونه برداری می کند بنابراین جامع نبوده و تمام ترکیبات را پوشش نمی دهد.

هزینه محاسباتی روش grid search بیشتر است و اگر تعداد hyperparameterها زیاد باشد، عملاً استفاده از این روش غیر ممکن است. در حالی که روش Random search در اینگونه موارد کارآمد تر است.

روش Grid search تضمین رسیدن به ترکیب بهینه ی hyperparameterها را می دهد اما روش دیگر، به نزدیکی ترکیب بهینه برسد (ممکن است به ترکیب بهینه نیز برسد)

پاسخ ۸ – House Pricing

در ابتدا دیتاست را خوانده و اطلاعات آن نمایش داده می شود.

	Id	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd	MasVnrArea
count	1460.000000	1460.000000	1201.000000	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000	1452.000000
mean	730.500000	56.897260	70.049958	10516.828082	6.099315	5.575342	1971.267808	1984.865753	103.685262
std	421.610009	42.300571	24.284752	9981.264932	1.382997	1.112799	30.202904	20.645407	181.066207
min	1.000000	20.000000	21.000000	1300.000000	1.000000	1.000000	1872.000000	1950.000000	0.000000
25%	365.750000	20.000000	59.000000	7553.500000	5.000000	5.000000	1954.000000	1967.000000	0.000000
50%	730.500000	50.000000	69.000000	9478.500000	6.000000	5.000000	1973.000000	1994.000000	0.000000
75%	1095.250000	70.000000	80.000000	11601.500000	7.000000	6.000000	2000.000000	2004.000000	166.000000
max	1460.000000	190.000000	313.000000	215245.000000	10.000000	9.000000	2010.000000	2010.000000	1600.000000

8 rows x 38 columns

شکل ۲۷. بخشی از اطلاعات آماری دیتاست

این دیتاست شامل ۱۴۶۰ ردیف و ۸۱ ستون است.

در ابتدا ستون هایی را که با دو مقدار مشخص شده اند، به هر مقدار یک عدد اختصاص می دهیم.

بطور مثال در ستون LotShape، برای Reg عدد صفر و برای IR1 عدد یک را اختصاص می دهیم.

در بخش پیش پردازش، ستون هایی که دارای missing value هستند مشخص می شود.

```
Column 'Alley' has 1369 missing values.
Column 'MasVnrType' has 8 missing values.
Column 'BsmtQual' has 37 missing values.
Column 'BsmtCond' has 37 missing values.
Column 'BsmtExposure' has 38 missing values.
Column 'BsmtFinType1' has 37 missing values.
Column 'BsmtFinType2' has 38 missing values.
Column 'Electrical' has 1 missing values.
Column 'FireplaceQu' has 690 missing values.
Column 'GarageType' has 81 missing values.
Column 'GarageFinish' has 81 missing values.
Column 'GarageQual' has 81 missing values.
Column 'GarageCond' has 81 missing values.
Column 'PoolQC' has 1453 missing values.
Column 'Fence' has 1179 missing values.
Column 'MiscFeature' has 1406 missing values.
```

شکل ۲۸. ستون هایی که دارای missing values هستند.

برخی از این ستون ها دارای تعداد زیادی missing values هستند: Alley و FireplaceQu و Fence و poolQC و MiscFeature این ستون ها از داده ها حذف می شوند.

برخی از ستون ها دارای مقادیر string بوده بنابراین از One-hot encoding استفاده می شود تا بتوان از کتابخانه SelectKbest استفاده کرد. این کتابخانه تنها مقادیر عددی را به عنوان ورودی دریافت می کند.

باقی ستون ها که تعدا محدودی مقدار نامعلوم دارند، به روش زیر جایگزین می شوند:


الف. ستون هایی که مقدار عددی دارند، مقادیر missing value با میانگین جایگزین شده اند.

ب. ستون هایی که مقادیر غیر عددی دارند که با 0 و 1 جایگزین شده بودند، با مد پر می شوند.

اکنون داده ها را به ۳ دسته ترین (۷۰٪) تست (۱۵٪) و ارزیابی (۱۵٪) تقسیم می کنیم.

همچنین در ورودی های کتابخانه SelectKBest، مقدار 'all' قرار گرفته است.

مدل را به وسیله کرنل خطی SVM آموزش داده و نتایج در ادامه قابل مشاهده خواهد بود.



شکل ۲۹. نمودار قیمت پیشبینی شده و قیمت واقعی

```
Test Set Evaluation for k = 'all':  
  
Mean Squared Error (MSE): 3380119014.540934  
R-squared (R2) Score: 0.48408093690748355
```

شکل ۳۰. نتایج مجموعه تست

```
Validation Set Evaluation for k = 'all':  
  
Mean Squared Error (MSE): 1318943207.655494  
R-squared (R2) Score: 0.7785611505688756
```

شکل ۳۱. نتایج مجموعه ارزیابی

