

به نام خدا



دانشگاه تهران



دانشکده مهندسی برق و کامپیوتر

درس یادگیری ماشین

تمرین سری پنجم

نام و نام خانوادگی	امیر غرقابی
شماره دانشجویی	۸۱۰۱۰۲۲۱۷
تاریخ ارسال گزارش	۱۴۰۲،۱۱،۰۸

فهرست

۱	پاسخ ۱
۳	پاسخ ۲
۶	پاسخ ۳
۷	پاسخ ۴
۸	پاسخ ۵
۱۰	پاسخ ۶ – PCA & K-NN
۱۳	پاسخ ۷ – Kmeans

شکل‌ها

- شکل ۱. نمونه و توصیفات دیتاست..... ۱۰
- شکل ۲. مقادیر ویژه..... ۱۰
- شکل ۳. مقادیر ویژه در تعداد کامپوننت های مختلف..... ۱۱
- شکل ۴. تعداد ۳۰ تا از بزرگترین مقادیر ویژه..... ۱۱
- شکل ۵. تصاویر کلاس شماره ۳ (Happy)..... ۱۲
- شکل ۶. ماتری آشفته‌گی داده ها قبل از اعمال PCA با دقت 35%..... ۱۲
- شکل ۷. ماتری آشفته‌گی داده ها پس از اعمال PCA با دقت 27%..... ۱۳
- شکل ۸. خطای MSE بر حسب تعداد رنگ..... ۱۴
- شکل ۹. سمت راست تصویر فشرده شده با ۵ رنگ و سمت چپ تصویر اصلی..... ۱۴



Subject :

Year . Month .

Date .

امیر محمدی

8.10.2217

فرمانی یادگیری ماشین

HW 5

$$P(y|\tilde{\theta}_1) = \frac{1}{\sqrt{2\pi}\tilde{\sigma}} \exp\left(-\frac{(y - \tilde{\mu})^2}{2\tilde{\sigma}^2}\right) \quad (1)$$

$$\tilde{\theta}_1 = \begin{bmatrix} \tilde{\mu} \\ \tilde{\sigma} \end{bmatrix}$$

$$r = \text{Loglikelihood} = \frac{\ln P(D|\tilde{\theta}_1)}{\ln P(D|\tilde{\theta}_2)}$$

$$= \frac{\ln \prod P(y_k|\tilde{\theta}_1)}{\ln \prod P(y_k|\tilde{\theta}_2)} = \frac{\sum \ln \frac{1}{\sqrt{2\pi}\tilde{\sigma}} + \sum \ln \frac{1}{2\tilde{\sigma}^2} \exp\left(-\frac{(y_k - \tilde{\mu})^2}{2\tilde{\sigma}^2}\right)}{\sum \ln \frac{1}{\sqrt{2\pi}\tilde{\sigma}} + \sum \ln \frac{1}{2\tilde{\sigma}^2} \exp\left(-\frac{(y_k - \tilde{\mu}_2)^2}{2\tilde{\sigma}_2^2}\right)}$$

$$= \frac{c_1 + \sum_{y_k \in D_1} \frac{(y_k - \tilde{\mu}_1)^2}{2\tilde{\sigma}_1^2} + \sum_{y_k \in D_2} \frac{(y_k - \tilde{\mu}_2)^2}{2\tilde{\sigma}_2^2}}{c_1 + \sum_{y_k \in D_1} \frac{(y_k - \tilde{\mu}_1)^2}{2\tilde{\sigma}_1^2} + \sum_{y_k \in D_2} \frac{(y_k - \tilde{\mu}_2)^2}{2\tilde{\sigma}_2^2}}$$

$$= \frac{c_1 + \frac{1}{2} + \sum_{y_k \in D_1} \frac{[(y_k - \tilde{\mu}_2) + (\tilde{\mu}_2 - \tilde{\mu}_1)]^2}{2\tilde{\sigma}_1^2}}{c_1 + \frac{1}{2} + \sum_{y_k \in D_1} \frac{[(y_k - \tilde{\mu}_2) + (\tilde{\mu}_2 - \tilde{\mu}_1)]^2}{2\tilde{\sigma}_1^2}}$$

$$= \frac{c_1 + \frac{1}{2} + \sum_{y_k \in D_1} \frac{[(y_k - \tilde{\mu}_2) + (\tilde{\mu}_2 - \tilde{\mu}_1)]^2}{2\tilde{\sigma}_1^2}}{c_1 + \frac{1}{2} + \sum_{y_k \in D_1} \frac{[(y_k - \tilde{\mu}_2) + (\tilde{\mu}_2 - \tilde{\mu}_1)]^2}{2\tilde{\sigma}_1^2}}$$

$$= \frac{c_1 + \frac{1}{2} + \frac{1}{2\tilde{\sigma}_1^2} \sum_{y_k \in D_1} \left((y_k - \tilde{\mu}_2)^2 + (\tilde{\mu}_2 - \tilde{\mu}_1)^2 + 2(y_k - \tilde{\mu}_2)(\tilde{\mu}_2 - \tilde{\mu}_1) \right)}{c_1 + \frac{1}{2} + \frac{1}{2\tilde{\sigma}_1^2} \sum_{y_k \in D_1} \left((y_k - \tilde{\mu}_2)^2 + (\tilde{\mu}_2 - \tilde{\mu}_1)^2 + 2(y_k - \tilde{\mu}_2)(\tilde{\mu}_2 - \tilde{\mu}_1) \right)}$$

$$= \frac{c_1 + \frac{1}{2} + \frac{1}{2\tilde{\sigma}_1^2} \sum_{y_k \in D_1} \left((y_k - \tilde{\mu}_2)^2 + (\tilde{\mu}_2 - \tilde{\mu}_1)^2 + 2(y_k - \tilde{\mu}_2)(\tilde{\mu}_2 - \tilde{\mu}_1) \right)}{c_1 + \frac{1}{2} + \frac{1}{2\tilde{\sigma}_1^2} \sum_{y_k \in D_1} \left((y_k - \tilde{\mu}_2)^2 + (\tilde{\mu}_2 - \tilde{\mu}_1)^2 + 2(y_k - \tilde{\mu}_2)(\tilde{\mu}_2 - \tilde{\mu}_1) \right)}$$

$$= \frac{\frac{C}{n_1 + 1} + \frac{1}{2s^2} n_2 (\hat{\mu}_2 - \hat{\mu}_1)^2}{\frac{C}{n_1 + 1} + \frac{1}{2s^2} n_1 (\hat{\mu}_1 - \hat{\mu}_2)^2} = \frac{C + n_2 J(w)}{C + n_1 J(w)}$$

5. $\rightarrow J(w) = \frac{rC - C}{n_2 - rn_1}$

بدین ترتیب ثابت شد که FLD از متنی نسبت به این احتمال (۲-۱)

نتیجه می شود.

10

15

20



Subject :

Year .

Month .

Date .

(2

$$p_x(x|w_i) : \mu_i, \Sigma_i$$

$$y = w^T x \quad \max J_1(w) = \frac{(\mu_1 - \mu_2)^2}{\sigma_1^2 + \sigma_2^2}$$

$$w^* = (\Sigma_1 + \Sigma_2)^{-1} (\mu_1 - \mu_2)$$

$$x \xrightarrow{y = w^T x} z : J_2(w) = \frac{\tilde{\mu}_1 - \tilde{\mu}_2}{\tilde{\sigma}_1^2 + \tilde{\sigma}_2^2}$$

$$\tilde{\mu}_1 = \mu_1(z) = \mu(w^T x) = w^T \mu_1 \quad (1) \quad \tilde{\Sigma}_1 = \frac{1}{n} \sum_{i=1}^n x_i x_i^T$$

$$\tilde{\mu}_2 = \mu_2(z) = w^T \mu_2 \quad (2)$$

$$n \tilde{\Sigma}_1 \triangleq S_1^2 ; \quad n \tilde{\Sigma}_2 \triangleq S_2^2$$

$$\tilde{\Sigma}(z) = E(z^2) - E(z)^2$$

$$E(z) = E(w^T x) = w^T E(x) = 0$$

فرستی اینجاست $E(x)$ است

اگر هم صفر نبود، می‌توانیم رابطه کرده و از داده کم می‌کنیم

$$\Rightarrow \tilde{\Sigma}(z) = \frac{1}{n} \sum_{i=1}^n z_i^2 = \frac{1}{n} \sum_{i=1}^n z_i z_i^T$$

$$\begin{aligned} \Rightarrow \tilde{S}_1^2 &= \sum_{i=1}^n z_i z_i^T = \sum_{i=1}^n (w^T x_i) (w^T x_i)^T = w^T \left(\sum_{i=1}^n x_i x_i^T \right) w \\ &= w^T S_1^2 w \end{aligned}$$

$$\Rightarrow \tilde{S}_2^2 = w^T S_2^2 w$$

حالا بگذاریم $J_2(w)$ را

$$J_2(w) = \frac{(w^T \mu_1 - w^T \mu_2)^2}{w^T S_1 w + w^T S_2 w}$$

$$= \frac{\overbrace{w^T (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T w}^{S_B}}{\underbrace{w^T (S_1 + S_2) w}_{S_W}}$$

$$\Rightarrow \max J_2(w) = \frac{w^T S_B w}{w^T S_W w}$$

غرضی کنیم مخرج برابر با ثابت k است

$$\rightarrow \max J_2(w) = \frac{w^T S_B w}{w^T S_W w}$$

$$s.t \quad w^T S_W w = k$$

آنگاه لاگرانژ را تشکیل می دهیم

$$L = w^T S_B w - \lambda (w^T S_W w - k)$$

$$L_w = 2 S_B w - 2 \lambda S_W w = 0$$

$$\rightarrow S_B w = \lambda S_W w \rightarrow \underbrace{S_W^{-1} S_B w}_A = \lambda w \quad \text{eigenvector}$$

حالا این دو تابع همبسته :

$$\max w^T S_B w = \lambda \underbrace{w^T S_W w}_k = k \lambda$$

بردار ویژه λ و بردار ویژه w در رابطه $S_W^{-1} S_B w = \lambda w$ قرار می گیرند.

$$\rightarrow \lambda w^* = S_W^{-1} S_B w^*$$

$$\lambda w = S_W^{-1} (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T w$$

$$a \frac{a^T u}{\alpha} = \alpha a$$

می دانیم:

$$\rightarrow \lambda w = S_w^{-1} \alpha (\mu_1 - \mu_2)$$

$$\rightarrow w = \frac{\alpha}{\lambda} S_w^{-1} (\mu_1 - \mu_2)$$

ضریب $\frac{\alpha}{\lambda}$ اهمیتی ندارد زیرا تنها جت w اهمیت دارد

$$\rightarrow w^* = S_w^{-1} (\mu_1 - \mu_2)$$

$$= (S_1^2 + S_2^2)^{-1} (\mu_1 - \mu_2)$$

$$= \lambda (\bar{\Sigma}_1 + \bar{\Sigma}_2)^{-1} (\mu_1 - \mu_2)$$

در اینجا نیز ضریب λ اهمیتی ندارد:

$$\rightarrow w^* = (\bar{\Sigma}_1 + \bar{\Sigma}_2)^{-1} (\mu_1 - \mu_2) \quad \square$$

(الف)

در داده هایی که ابعاد بالا دارند مشکلات متعددی را ایجاد می کنند. مثلاً مدل بسیار پیچیده می شود که باعث افزایش خطای واریانس می شود. برای همین از روش های کاهش بعد مانند PCA و LDA استفاده می شود. در این روش ها نیز اگر ابعاد زیاد باشد محاسبات بسیار پیچیده می شوند. بطور مثال در LDA نیاز به محاسبه معکوس ماتریس Sw است. در ابعاد بالا، این محاسبه نیاز به منابع محاسباتی قوی دارد. همچنین اگر ابعاد کاهش یابند، بسیاری از ویژگی های مهم نیز ممکن است از دست بروند. همچنین تفسیرپذیری هر ویژگی نیز از بین می رود.

برای مشکلات محاسباتی، می توان به جای استفاده از تمام نمونه ها، یک زیر-نمونه (Subsample) از کل داده ها را استخراج کرده و محاسبات را روی آن انجام داد و یا از روش های محاسباتی موازی استفاده کرد. همچنین از روش های Incremental PCA و Incremental LDA نیز می توان استفاده کرد که این امکان را می دهد تا در تکرار های مختلف، مدل را آپدیت کرد و در هر تکرار بخشی از داده را در نظر گرفت. همچنین می توان از الگوریتم های بهینه سازی نیز بهره برد.

(ب)

مزایا: استفاده از متریک های دیگر می تواند منجر به این شود که بدون از دست دادن برخی از اطلاعات مهم، ابعاد کاهش یابد.

همچنین با استفاده از اطلاعات متقابل داده ها می توان از تبدیل های بهتری استفاده کرد که در نهایت منجر به طبقه بندی بهتر داده ها می شود.

هجهجه

معایب: برای استفاده از اطلاعات متقابل داده ها و لیبل، به لیبل داده ها لازم است بنابراین که در صورت نبود برچسب ها، محدودیت محسوب می شود.

همچنین ممکن است به پیچیدگی محاسباتی بیافزاید.



Subject :

Year .

Month .

Date .

$$P(x|z) = \mathcal{N}(x|wz + \mu, \sigma^2 I) \quad (4) \text{ الف}$$

$$\text{Cov}(p|n) = \mathcal{N}(x|\mu, \sigma^2 I) = w w^T + \sigma^2 I$$

$$5 \quad p(\mu) = \int p(x|z) p(z) dz \rightarrow p(z) = \mathcal{N}(z|\mu_z=0, I)$$

$$\begin{aligned} \mu_x = E(\mu) &= E(wz + \mu + \sigma) = E(wz) + \mu + \sigma \\ &= w E(z) + \mu + \sigma = \mu \end{aligned}$$


$$\begin{aligned} 10 \quad \text{Cov}(\mu) &= E\{(\mu - \mu)(\mu - \mu)^T\} = E(wz + \mu - \mu + \sigma)(wz + \mu - \mu + \sigma)^T \\ &= E\{wz\} + E\{\sigma^2\} = E(wz z^T w) + E\{\sigma^2\} \\ &= w E\{z z^T\} w^T + E\{\sigma^2\} \end{aligned}$$

$$15 \quad \text{Cov}(z) = E\{z z^T\} = \frac{\mu_{z=0}}{\sigma_z^2=1} = I$$

$$\rightarrow \text{Cov}(\mu) = w \text{Cov}(z) w^T + E\{\sigma^2\} = w w^T + \sigma^2 I$$



Subject :
Year . Month . Date .



$$\mu_{c_1} = \frac{1}{3} (x_1 + x_2 + x_4) = \left(\frac{5}{3}, \frac{2}{3} \right)$$

$$\mu_{c_2} = \frac{1}{2} (x_3 + x_5) = (3.25, 1)$$

الت

$$\min (\|x_i - \mu_{c_1}\|, \|x_i - \mu_{c_2}\|)$$

$$x_1: \min (2.13, 3.4) = 2.13 \rightarrow c_1$$

$$x_2: \min (1.79, 3.4) = 1.79 \rightarrow c_1$$

$$x_3: \min (0.68, 2.05) = 0.68 \rightarrow c_1$$

$$x_4: \min (3.99, 2.01) = 2.01 \rightarrow c_2$$

$$x_5: \min (3.59, 2.01) = 2.01 \rightarrow c_2$$

گروه های 3 و 4، خوشه ها را نشان می دهند. الگو را بنویسید و آن را رنگ کنید

$$\mu_{c_1} = \frac{1}{3} (x_1 + x_2 + x_3) = \left(\frac{2}{3}, \frac{2}{3} \right)$$

$$\mu_{c_2} = \frac{1}{2} (x_4 + x_5) = (5, 1)$$

$$x_1: \min (1.49, 5.0) = 1.49 \rightarrow c_1$$

$$x_2: \min (0.94, 5.0) = 0.94 \rightarrow c_1$$

$$x_3: \min (1.06, 3.64) = 1.06 \rightarrow c_1$$

$$x_4: \min (4.3, 1) = 1 \rightarrow c_2$$

$$x_5: \min (4.5, 1) = 1 \rightarrow c_2$$

$$c_1: \{x_1, x_2, x_3\} \quad ; \quad c_2: \{x_4, x_5\}$$

جواب

$$\mu_{c_1^2} = (1.5, 2.3)$$

$$\mu_{c_2^2} = (3.25, 1)$$

5

$$x_1: \min(3, 4.5) = 3 \rightarrow c_1$$

$$x_2: \min(4.3, 3.9) = 1.3 \rightarrow c_1$$

$$x_3: \min(0.8, 2.4) = 0.8 \rightarrow c_1$$

$$x_4: \min(3.1, 2.4) = 2.4 \rightarrow c_2$$

$$10 \quad x_5: \min(4.6, 3.08) = 3.08 \rightarrow c_2$$

$$\mu_{c_1^3} = (2.3, 2.3)$$

$$\mu_{c_2^3} = (5.0, 1)$$

فهرست تغییر کرد

$$15 \quad x_1: \min(2, 6.3) = 2 \rightarrow c_1$$

$$x_2: \min(1.3, 5.6) = 1.3 \rightarrow c_1$$

$$x_3: \min(2.3, 6.1) = 2 \rightarrow c_1$$

$$x_4: \min(5, 0.6) = 0.6 \rightarrow c_2$$

$$x_5: \min(5.6, 1.3) = 1.3 \rightarrow c_2$$

20

فهرست تغییر کرد

$$c_1: \{x_1, x_2, x_3\}; \quad c_2: \{x_4, x_5\}$$

25

پاسخ ۶ – PCA & K-NN

الف)

دیتا ست fer2013.csv را توسط کتابخانه pandas لود میکنیم.

```
data.head

<bound method NDFrame.head of      emotion      pixels      Usage
0      0      70 80 82 72 58 58 60 63 54 58 60 48 89 115 121...  Training
1      0      151 150 147 155 148 133 111 140 170 174 182 15...  Training
2      2      231 212 156 164 174 138 161 173 182 200 106 38...  Training
3      4      24 32 36 30 32 23 19 20 30 41 21 22 32 34 21 1...  Training
4      6      4 0 0 0 0 0 0 0 0 0 0 3 15 23 28 48 50 58 84...  Training
...
35882      6      50 36 17 22 23 29 33 39 34 37 37 37 39 43 48 5...  PrivateTest
35883      3      178 174 172 173 181 188 191 194 196 199 200 20...  PrivateTest
35884      0      17 17 16 23 28 22 19 17 25 26 20 24 31 19 27 9...  PrivateTest
35885      3      30 28 28 29 31 30 42 68 79 81 77 67 67 71 63 6...  PrivateTest
35886      2      19 13 14 12 13 16 21 33 50 57 71 84 97 108 122...  PrivateTest

[35887 rows x 3 columns]>

data.describe

<bound method NDFrame.describe of      emotion      pixels      Usage
0      0      70 80 82 72 58 58 60 63 54 58 60 48 89 115 121...  Training
1      0      151 150 147 155 148 133 111 140 170 174 182 15...  Training
2      2      231 212 156 164 174 138 161 173 182 200 106 38...  Training
3      4      24 32 36 30 32 23 19 20 30 41 21 22 32 34 21 1...  Training
4      6      4 0 0 0 0 0 0 0 0 0 0 3 15 23 28 48 50 58 84...  Training
...
35882      6      50 36 17 22 23 29 33 39 34 37 37 37 39 43 48 5...  PrivateTest
35883      3      178 174 172 173 181 188 191 194 196 199 200 20...  PrivateTest
35884      0      17 17 16 23 28 22 19 17 25 26 20 24 31 19 27 9...  PrivateTest
35885      3      30 28 28 29 31 30 42 68 79 81 77 67 67 71 63 6...  PrivateTest
35886      2      19 13 14 12 13 16 21 33 50 57 71 84 97 108 122...  PrivateTest

[35887 rows x 3 columns]>
```

شکل ۱. نمونه و توصیفات دیتاست

در ستون Pixels، مقادیر پیکسل ها در یک آرایه قرار گرفته اند. هرکدام از مقادیر را جدا کرده، و به صورت float32 و در یک آرایه در متغیری به نام X قرار می دهیم.

سپس با استفاده از کتابخانه PCA، مقادیر ویژه را بدست آورده و پرینت میکنیم. نتایج در شکل های زیر قابل مشاهده است.


```
> eigenvalues = pca.explained_variance_
> eigenvalues_descending = np.sort(eigenvalues)[::-1]

# Print the eigenvalues in descending order
print(eigenvalues_descending)

[2.6651232e+06 9.0313669e+05 8.6841450e+05 ... 4.2908258e+00 4.1755352e+00
 3.8545706e+00]
```


شکل ۲. مقادیر ویژه

برای درک بهتر تفاوت مقادیر ویژه، آن ها را رسم میکنیم.



شکل ۳. مقادیر ویژه در تعداد کامپوننت های مختلف

مشاهده می شود که در نمودار، از حدود ۳۰ کامپوننت به بعد، مقادیر ویژه بسیار کوچک می شوند.



شکل ۴. تعداد ۳۰ تا از بزرگترین مقادیر ویژه

در $k=5$ ، نمودار یک زانو دارد. بنابراین این مقدار بهینه برای تعداد کامپوننت ها است.

(ب)

به ازای $n_components=5$ تصاویر را برای کلاس شماره ۳ (Happy) نشان می دهیم.


```

first_5_eigenfaces = pca.components_[:5]

# 4. Visualize the first 5 eigenfaces
plt.figure(figsize=(10, 4))
for i in range(4):
    plt.subplot(1, 5, i + 1)
    eigenface = first_5_eigenfaces[i].reshape(48, 48)
    plt.imshow(eigenface, cmap='gray')
    plt.title(f'Eigenface {i+1}')
    plt.axis('off')

plt.tight_layout()
plt.show()


```



شکل ۵. تصاویر کلاس شماره ۳ (Happy)

(ج)

اکنون از طبقه بند KNN برای داده های کاهش بعد یافته و داده های خالص اعمال کرده و CCR را گزارش داده و ماتریس آشفته گی را رسم می کنیم.



شکل ۶. ماتری آشفته گی داده ها قبل از اعمال PCA با دقت 35%

Classification Report:
 PCA-Reduced Data:
 Accuracy: 0.2751462803009195

Confusion Matrix - PCA-Reduced Data

0	285	11	126	258	136	68	101
1	16	28	11	18	10	11	8
2	175	15	285	258	131	88	91
3	289	26	230	675	215	158	172
4	219	9	172	324	267	71	148
5	109	20	124	187	68	229	58
6	231	21	153	385	179	103	206
	0	1	2	3	4	5	6

True Labels


Predicted Labels

شکل ۷. ماتری آشفته‌گی داده‌ها پس از اعمال PCA با دقت 27%

بنظر می‌رسد که در کد مشکلی وجود دارد و هر دو طبقه بندی از دقت پایین برخوردار هستند. اگرچه انتظار میرفت که دقت این دو طبقه بند تفاوت چندانی نداشته و دقت خوبی داشته باشند.

پاسخ ۷ – Kmeans


در این سوال از روش K-means برای فشرده سازی تصاویر استفاده می‌کنیم در واقع رنگ تصویر را به k خوشه مختلف تقسیم میکنیم. این کار را برای 1 الی 30 خوشه مختلف انجام می‌دهیم. در هر باری که تصویر به k خوشه تقسیم می‌شود، مقدار MSE محاسبه شده و نمودار MSE بر حسب تعداد K مختلف رسم می‌شود.



شکل ۸. خطای MSE بر حسب تعداد رنگ

از نمودار مشخص است که مقدار خطا در $K=5$ یک زانو دارد.

بنابراین از همین تعداد رنگ برای فشرده کردن عکس استفاده می کنیم.



شکل ۹. سمت راست تصویر فشرده شده با ۵ رنگ و سمت چپ تصویر اصلی

همانطور که در تصویر نیز مشخص است، تصویر سمت راست (کاهش بعد یافته) تقریب بسیار خوب و مناسبی از تصویر سمت چپ (اصلی) است.